

STATISTICAL HEALTH REPORT

PANDAS-DEV/PANDAS

Target Repositori : pandas-dev/pandas

Tautan Repositori Proyek : <https://github.com/DRNCW/stat-audit-pandas-Tim7--sti-2025.git>

Tautan Video Presentasi Proyek : <https://drive.google.com/drive/folders/1clxVx-MCbFbGoGSMruThOsIF1xt9LZIV>

Program Studi : Sistem dan Teknologi Informasi

Fakultas / Kampus : Teknik / Universitas Negeri Jakarta

Member	Nama	NIM	Peran
A	Darren Chandra Wijaya	1519625019	Data Engineer
B	Muhammad Zulhaydar Omar Rafiq	1519625046	Estimation Analyst
C	Michelle Fiorentina Wong	1519625024	Inference Analyst
D	Bonita Zhafira Mulyowijoyo	1519625035	Hypothesis Analyst
E	Kumara Tsany Widyadana	1519625034	Computation Analyst

1. Executive Summary

Laporan ini menyajikan audit statistik menyeluruh terhadap repositori pandas-dev/pandas untuk mengevaluasi efisiensi manajemen kontribusi dan stabilitas perangkat lunak sebelum dan sesudah rilis arsitektur besar versi 2.0. Analisis ini menggunakan basis data bersih hasil pre-processing sebanyak 3.228 Pull Requests (PR) dan 6.751 issuess serta dataset runtun waktu isu bug bulanan sepanjang periode 1 Januari 2021 hingga 31 Desember 2025 (60 bulan).

Ada lima temuan kritis yang disertai rekomendasi spesifik untuk pengelola pemeliharaan:

- Tingkat merge PR tetap stabil di angka 70,85% ($\theta = 0,7085$). Dari total 3.228 PR valid, sebanyak 2.287 berhasil digabungkan. MLE Bernoulli menunjukkan $\theta = 0,7085$ dengan CI 95% [0,6928; 0,7242]. Pengelola pemeliharaan perlu mengevaluasi 941 PR yang ditolak (29,15%) untuk memperbaiki pedoman kontribusi.
- Versi 2. 0 dari Pandas jelas telah menurunkan jumlah laporan bug sekitar 28,4%. Z-test untuk dua sampel menunjukkan penurunan dari $\lambda_1 = 60,56$ menjadi $\lambda_2 = 43,39$ bug per bulan ($Z = 4,086$; $p = 0,000044$). Hipotesis nol (H_0) secara tegas ditolak. Dibutuhkan pengawasan yang berkelanjutan untuk menjamin bahwa tren positif ini bisa dipertahankan pada rilis berikutnya.
- 40,8% issue melebihi batas waktu penyelesaian 30 hari. Dari total 6.751 issue, sebanyak 2.754 (40,79%) tidak selesai dalam waktu tersebut. Distribusi waktu penyelesaian menunjukkan kecenderungan yang sangat tinggi ke arah kanan atau right-skewed (median: 12,54 hari; rata-rata: 162,43 hari; maksimum: 1.942,94 hari). Diperlukan penerapan Perjanjian Tingkat Layanan (SLA) dan penggunaan bot triase otomatis secara mendesak.
- Referensi Bayesian menguatkan estimasi yang berbasis frekuensi. Beta posterior (2288; 942) memberikan interval kepercayaan 95% sebesar (0,6926; 0,7239), yang hanya berbeda 0,001 dari CI Wald (0,6928; 0,7242). Keselarasan ini menunjukkan kekuatan dari estimasi yang ada.

- Filter Bloom direkomendasikan untuk mendeteksi issue yang sama secara langsung. Metode berbasis probabilitas ini, dalam $O(m \text{ bit})$, jauh lebih efisien dalam penggunaan memori dibandingkan dengan menyimpan seluruh judul issue, sehingga sangat cocok untuk penyaringan otomatis sebelum memasukkan issue baru ke dalam antrian.

2. Data Overview

2.1 Sumber Data

Data diperoleh melalui GitHub REST API dari repositori pandas-dev/pandas dengan menggunakan token akses pribadi GitHub (5.000 permintaan per jam). Repositori ini diambil karena tingginya jumlah permintaan penggabungan dan masalah, konsistensi label yang baik, serta adanya eksperimen yang berlangsung: rilis Pandas 2.0 pada 3 April 2023. Data mengenai masalah diambil melalui API pencarian GitHub, dengan iterasi setiap bulan menggunakan opsi “pd. date_range”, untuk melewati batas 1.000 hasil per kueri.

Repositori Target	https://github.com/pandas-dev/pandas
Repositori Project	https://github.com/DRNCW/stat-audit-pandas-Tim7--sti-2025
API	GitHub REST API v3 (/repos/{owner}/{repo}/pulls, /search/issues)
Rentang Waktu	1 Januari 2021 – 31 Desember 2025 (60 bulan)
Pengambilan Data	Mei – Juni 2026; GitHub PAT (scope: public_repo); rate limit 5.000 req/jam
Metode	Python requests + paginasi 100 item/hal. Pemecahan per-bulan untuk mengatasi batas 1.000 hasil/query Search API

2.2 Ringkasan Dataset Pasca-Cleaning

Kategori Data / Metrik	Jumlah Sampel (n)	Representasi Persentase (%)	Relevansi Analisis
Total PR Bersih	3.228	100%	Basis Utama RQ1
Total Issues Bersih	6.751	100%	Basis Utama RQ3
Merged PRs (k)	2.287	70,85%	Estimasi Sukses Proporsi
Closed Unmerged PRs (n – k)	941	29,15%	Kegagalan Kontribusi
Total Isu Bug Bulanan	60 bulan	100%	Basis Utama RQ2
Periode Pre-v2.0	27 bulan	45%	Januari 2021 – Maret 2023
Periode Post-v2.0	33 bulan	55%	April 2023 – Desember 2025

2.3 Keterbatasan Data

- Batasan pengambilan sampel: API GitHub memberikan maksimal 5.000 permintaan tarik (pull request/PR). Jadi, PR yang lebih tua mungkin tidak akan ada.
- Batas waktu publikasi: Dampak arsitektur Pandas 2.0 mungkin tidak terasa selama beberapa bulan setelah April 2023. Oleh karena itu, pilihan batas waktu memengaruhi λ .
- Bias dalam penandaan: Tidak semua bug diberi tanda dengan cara yang sama. Akibatnya, beberapa mungkin terlewatkan.
- Right Censoring: Isu tetap ada meskipun pengumpulan data tidak dilakukan, yang mengurangi lamanya waktu.

3. Parameter Estimation

Bab ini membahas mengenai estimasi titik (*point estimation*) untuk mengunci nilai parameter populasi yang tidak diketahui berdasarkan sampel data historis bersih dari repositori pandas-dev/pandas. Estimasi titik dilakukan secara analitik menggunakan dua pendekatan utama: *Maximum Likelihood Estimation* (MLE) yang mewakili mazhab frekuentis, dan pencarian distribusi posterior yang mewakili mazhab Bayesian. Fokus estimasi diarahkan pada probabilitas keberhasilan penggabungan kontribusi kode (RQ1) dan laju kemunculan *defect* perangkat lunak per bulan sebelum versus sesudah rilis besar arsitektur Pandas 2.0 (RQ2).

3.1 RQ1 MLE Bernoulli: Probabilitas PR di-Merge

Status akhir penggabungan dari setiap *Pull Request* (PR) yang masuk ke repositori dimodelkan sebagai variabel acak independen dan berdistribusi identik (*independent and identically distributed* / i.i.d.) mengikuti sebaran Bernoulli, $X_i \sim \text{Bernoulli}(\theta)$, di mana $X_i = 1$ melambangkan PR berhasil di-merge (sukses), dan $X_i = 0$ jika ditolak atau closed unmerged (gagal).

Fungsi probabilitas massa (PMF) untuk satu observasi Bernoulli didefinisikan sebagai:

$$P(X_i = x_i) = \theta^{x_i}(1 - \theta)^{1-x_i}$$

Untuk sampel acak bersih berukuran n , fungsi likelihood $L(\theta)$ dibangun melalui perkalian produk PMF masing-masing observasi:

$$L(\theta) = \prod_{i=1}^n \theta^{x_i}(1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}$$

Dengan mensubstitusikan total jumlah PR yang berhasil di-merge sebagai $k = \sum_{i=1}^n x_i$, maka fungsi likelihood disederhanakan menjadi:

$$L(\theta) = \theta^k (1 - \theta)^{n-k}$$

Untuk mempermudah operasi diferensiasi, fungsi likelihood ditransformasikan ke bentuk fungsi log-likelihood analitik ($l(\theta)$):

$$l(\theta) = \ln L(\theta) = k \ln(\theta) + (n - k) \ln(1 - \theta)$$

Guna memperoleh nilai estimator kemungkinan maksimum ($\widehat{\theta}_{\text{MLE}}$), dilakukan diferensiasi turunan pertama terhadap parameter θ dan menyamakannya dengan nol:

$$\frac{dl(\theta)}{d\theta} = \frac{k}{\theta} - \frac{n - k}{1 - \theta} = 0$$

$$\frac{k}{\theta} = \frac{n-k}{1-\theta} \Rightarrow k(1-\theta) = \theta(n-k)$$

$$k - k\theta = n\theta - k\theta \Rightarrow n\theta = k \Rightarrow \widehat{\theta}_{MLE} = \frac{k}{n}$$

Berdasarkan pemrosesan data riil pada *layer* EDA, dari total sampel bersih $n = 3.228$ diperoleh volume PR sukses $k = 2.287$. Substitusi angka tersebut menghasilkan nilai estimasi titik frekuentis sebesar:

$$\widehat{\theta}_{MLE} = \frac{2287}{3228} = 0,785$$

3.2 RQ1 Posterior Bayesian: Beta-Binomial Conjugate Pair

Pendekatan Bayesian digunakan untuk memperbarui estimasi parameter dengan mengombinasikan informasi data sampel empiris dengan pengetahuan awal (*prior knowledge*). Berdasarkan ketentuan penulisan, digunakan prior non-informatif seragam (*uniform prior*) yang melambangkan ketiadaan preferensi informasi awal mengenai performa penggabungan kode, sehingga disetel parameter prior $p \sim \text{Beta}(\alpha_0 = 1, \beta_0 = 1)$.

Sifat konjugat (*conjugate priors*) dari sebaran Beta terhadap likelihood Binomial menghasilkan fungsi posterior analitik yang ditentukan melalui penambahan parameter sukses (k) dan gagal ($n - k$):

$$p | \text{data} \sim \text{Beta}(\alpha_0 + k, \beta_0 + n - k)$$

$$p | \text{data} \sim \text{Beta}(1 + 2287, 1 + 3228 - 2287) = \text{Beta}(2288, 942)$$

Dari fungsi sebaran posterior $\text{Beta}(2288, 942)$ tersebut, metrik pemusatan titik ditentukan melalui dua indikator kuantitatif:

- **Posterior Mean:** $\frac{\alpha}{\alpha+\beta} = \frac{2288}{2288+942} = 0,7084$
- **Posterior Mode:** $\frac{\alpha-1}{\alpha+\beta-2} = \frac{2287}{3228} = 0,7085$

Nilai puncak (*mode*) dari distribusi posterior terbukti identik secara mutlak dengan nilai estimator frekuentis ($\widehat{\theta}_{MLE}$). Hal ini mencerminkan fenomena statistik di mana ukuran sampel empiris yang besar ($n = 3.228$) mendominasi pengaruh sebaran prior non-informatif secara total.

3.3 RQ2 MLE Poisson: Laju Laporan Bug per Bulan

Frekuensi kemunculan laporan isu berkategori bug per bulan diasumsikan mengikuti proses stokastik Poisson secara independen dan berdistribusi identik, $X_t \sim \text{Poisson}(\lambda)$, di mana t melambangkan indeks bulan pengamatan dan λ melambangkan laju rata-rata bug bulanan.

Fungsi probabilitas massa (PMF) dari distribusi Poisson untuk satu unit periode observasi didefinisikan sebagai:

$$P(X_t = x_t) = \frac{e^{-\lambda} \lambda^{x_t}}{x_t!}$$

Untuk sampel runtun waktu berukuran n bulan, fungsi likelihood $L(\lambda)$ diderivasikan sebagai perkalian produk PMF:

$$L(\lambda) = \prod_{t=1}^n \frac{e^{-\lambda} \lambda^{x_t}}{x_t!} = \frac{e^{-n\lambda} \lambda^{\sum_{t=1}^n x_t}}{\prod_{t=1}^n x_t!}$$

Transformasi ke dalam fungsi log-likelihood analitik ($l(\lambda)$) menghasilkan:

$$l(\lambda) = -n\lambda + \left(\sum_{t=1}^n x_t \right) \ln(\lambda) - \sum_{t=1}^n \ln(x_t!)$$

Turunan pertama terhadap parameter λ dilakukan dan disamakan dengan nol untuk mengunci nilai maksimum kemungkinan parameter populasi:

$$\frac{dl(\lambda)}{d\lambda} = -n + \frac{\sum_{t=1}^n x_t}{\lambda} = 0 \Rightarrow \frac{\sum_{t=1}^n x_t}{\lambda} = n \Rightarrow \widehat{\lambda}_{MLE} = \frac{\sum_{t=1}^n x_t}{n}$$

Guna mengevaluasi dampak restrukturisasi arsitektur repositori secara kronologis, estimasi titik laju Poisson dibagi secara ketat ke dalam dua partisi periode pengamatan berdasarkan *milestone* rilis besar Pandas 2.0 (April 2023):

1. **Periode Pre-v2.0** ($n_1 = 27$ bulan): Akumulasi total data menghasilkan nilai estimasi laju bug bulanan sebesar $\widehat{\lambda}_1 = 60,5556$ bug/bulan.
2. **Periode Post-v2.0** ($n_2 = 33$ bulan): Akumulasi total data menghasilkan nilai estimasi laju bug bulanan sebesar $n_2 = 33$ bulan.

Komparasi analitik antara kedua nilai estimasi titik ini menunjukkan adanya penurunan laju defect absolut yang sangat kontras sebesar 17,1616 bug/bulan atau setara dengan reduksi frekuensi kegagalan sistem sebesar **28,34%** setelah modernisasi kode diimplementasikan.

Keseluruhan parameter numerik hasil kalkulasi analitik pada bab ini dirangkum secara komprehensif pada Tabel berikut:

Model Variabel Acak	Parameter Populasi	Pendekatan Estimasi	Formula Komputasi Analitik	Hasil Estimasi Titik Riil
Bernoulli i.i.d. (Pull Request State)	θ	Maximum Likelihood (MLE)	$\widehat{\theta}_{MLE} = \frac{k}{n}$	2287 / 3228 = 70,85%
Beta-Binomial Pair (Prior Non-Informatif)	θ	Bayesian Posterior Mode	$\frac{\alpha - 1}{\alpha + \beta - 2}$ Beta(2288,942)	(2288 - 1) / (2288 + 942 - 2) = 70,85%
Poisson i.i.d. (Laju Bug Pre-v2.0)	λ_1	Maximum Likelihood (MLE)	$\widehat{\lambda}_1 = \frac{\sum_b^a X_{t1}}{n_1}$	1635 bug / 27 bulan = 60,5556 bug/bulan
Poisson i.i.d. (Laju Bug Post-v2.0)	λ_2	Maximum Likelihood (MLE)	$\widehat{\lambda}_2 = \frac{\sum_q^p X_{t2}}{n_2}$	1432 bug / 33 bulan = 43,3939 bug/bulan

4. Confidence Intervals

Semua CI dihitung dengan tingkat kepercayaan sebesar 95% ($\alpha = 0,05$). Laporan ini menyajikan analisis statistik inferensial untuk mengetahui karakteristik parameter populasi berdasarkan data sampel yang tersedia. Pendekatan inferensi dibagi menjadi dua bagian utama: Pendekatan Frequentist (Estimasi Interval Mean, Bernoulli, dan Poisson) yang berbasis pada frekuensi jangka panjang (*long-run frequency*), serta Pendekatan Bayesian (Credible Interval) yang merepresentasikan pembaruan keyakinan (*updated belief*). Rentang spesifik yang diperoleh bukanlah pernyataan tentang probabilitas posisi parameter dalam perspektif frekuentis, parameter tersebut bersifat tetap (bukan sebagai variabel acak).

4.1 CI Merge Rate PR dengan Metode Wald (RQ1)

Pada bagian ini mengukur ketidakpastian dari proporsi keberhasilan sistem berdasarkan data biner (*merged vs rejected*). Dari total sampel $n = 3.228$, terdapat $k = 2.287$ kasus sukses (*merged*) dan $m = 941$ kasus gagal (*rejected*), menghasilkan estimasi proporsi ($\hat{p}$) sebesar 0,7085.

Prasyarat Wald : $n\hat{p} = 2.287 \gg 5$ dan $n(1 - \hat{p}) = 941 \gg 5$

$$SE(\hat{p}) = \sqrt{(0,7085 \times 0,2915 / 3.228)} = 0,00799$$

$$CI_{95\%}(p) = \hat{p} \pm 1.96 \times SE(\hat{p}) = 0,7085 \pm 1,96 \times 0,00799 = 0,7085 \pm 0,0157 \Rightarrow (0,6928 ; 0,7242)$$

Apabila prosedur pengambilan sampel dan konstruksi interval ini diulang berkali-kali dalam kondisi yang sama, sekitar 95% interval yang terbentuk akan mencakup nilai proporsi sebenarnya dari populasi. Interval (0,6928, 0,7242) merupakan salah satu realisasi dari prosedur tersebut. Margin kesalahan sebesar $\pm 1.57\%$ menunjukkan bahwa estimasi proporsi merge rate cukup presisi. Untuk sampel spesifik ini, kita meyakini sebesar 95% bahwa parameter rata-rata keberhasilan pull request populasi berada dalam rentang interval [0,6928, 0,7242].

4.2 Bayesian Credible Interval (RQ1)

Hal ini menjawab pertanyaan probabilitas mengenai rentang nilai sesungguhnya dari tingkat keberhasilan *pull request* dengan mengombinasikan keyakinan awal dan data aktual.

Dengan posterior $p \mid \text{data} \sim \text{Beta}(2288, 942)$:

$$CrI_{95\%}(p) = (Q_{0,025}(\text{Beta}(2288, 942)) ; Q_{0,975}(\text{Beta}(2288, 942))) = (0,6926 ; 0,7239)$$

Berdasarkan data yang diamati dan distribusi prior Beta (1,1), terdapat tingkat keyakinan 95% bahwa nilai probabilitas parameter keberhasilan pull request populasi sebenarnya dari parameter p berada dalam rentang antara 0,6926 dan 0,7239. Interpretasi ini berbeda dari confidence interval frequentist karena secara Bayesian parameter diperlakukan sebagai variabel acak yang memiliki distribusi posterior. Kedekatan hasil antara credible interval dan confidence interval Wald menunjukkan bahwa ukuran sampel yang besar membuat informasi dari data lebih dominan dibandingkan pengaruh prior.

4.3 CI Laju Bug Poisson dengan Metode Wald (RQ2)

Dari data jumlah bug:

$$\lambda^{\wedge} = 50.95$$

Menggunakan metode exact Poisson berbasis distribusi Chi-Square diperoleh:

$$CI_{95\%}(\lambda) = (49.16, 52.79)$$

Interpretasi frekuentis: Apabila metode pengumpulan data dan proses observasi ini diulang berkali-kali dari proses Poisson yang sama, maka sekitar 95% interval yang dihasilkan akan mencakup nilai sebenarnya dari parameter λ . Berdasarkan data yang diamati, laju rata-rata kejadian bug diperkirakan berada pada rentang antara 49,16 dan 52,79 kejadian per periode pengamatan. Interval yang relatif sempit menunjukkan bahwa estimasi laju bug memiliki tingkat ketelitian yang baik.

4.4 Estimasi Interval Rata-Rata (Confidence Interval Mean)

Analisis ini bertujuan untuk mengestimasi rata-rata tingkat keberhasilan *pull request* (PR) yang berhasil di-merge pada repositori yang diteliti.

$$CI = \bar{\theta} \pm z(\alpha/2) (s/\sqrt{n})$$

Jika kita mereplikasi prosedur pengambilan sampel ini secara berulang kali dalam jangka panjang, maka 95% dari rentang interval yang terbentuk akan mencakup nilai rata-rata populasi μ yang sebenarnya. Untuk sampel spesifik ini, kita meyakini sebesar 95% bahwa parameter rata-rata keberhasilan pull request populasi berada dalam rentang interval [0,6928, 0,7242]."

4.5 Ringkasan Semua Interval

No	Metode	Batas Bawah	Batas Atas
1	Confidence Interval Mean	0,6928	0,7242
2	Confidence Interval Bernoulli	0,6928	0,7242
3	Confidence Interval Poisson	49,1597	52,7888
4	Bayesian Credible Interval	0,6926	0,7239

Hasil estimasi interval menunjukkan konsistensi yang sangat tinggi antara pendekatan Frequentist dan Bayesian untuk parameter keberhasilan *pull request* (sekitar 69,2% hingga 72,4%).

5. Hypothesis Testing

Keputusan pengujian hanya bisa berupa "Tolak H_0 " atau "Gagal Tolak H_0 ", tidak ada istilah "Terima H_0 ". Level signifikansi $\alpha = 0,05$ untuk semua jenis uji.

5.1 RQ1 Uji Satu Sampel: Apakah Merge Rate Berbeda dari Benchmark 75%?

Langkah 1: Formulasi Hipotesis

$H_0 : p = 0,75$ (merge rate SAMA dengan benchmark OSS) $H_1 : p \neq 0,75$ (uji DUA SISI)

Langkah 2: Tingkat Signifikansi

$\alpha = 0,05$ (toleransi error Tipe I sebesar 5%).

Langkah 3: Statistik Uji

Untuk satu sampel proporsi dengan n besar (CLT berlaku, $n\hat{p} \gg 5$):

$$Z = (\hat{p} - p_0) / \sqrt{(p_0(1 - p_0)/n)} = (0,8042 - 0,75) / \sqrt{(0,75 \times 0,25/16.213)} = 0,0542 / 0,003402 = 15,93$$

Langkah 4: Niali Kritis

zkritis = $\pm 1,9600$; daerah penolakan: $|Z| > 1,96$.

Langkah 5: P-Value

$$p\text{-value} = 2 \times P(Z > 15,93) \approx 2,2 \times 10^{-57}$$

Langkah 6: Keputusan dan Kesimpulan

$$|Z_{hitung}| = 15,93 \gg z_{kritis} = 1,96 \text{ dan } p\text{-value} \approx 2,2 \times 10^{-57} \ll \alpha = 0,05$$

$\Rightarrow$ TOLAK H_0 . Terdapat bukti statistik yang sangat kuat bahwa merge rate pandas-dev/pandas ($\hat{p} = 0,8042$) secara signifikan berbeda dari benchmark OSS 75%, dan jauh lebih tinggi. Hal ini menunjukkan bahwa komunitas pandas menerapkan standar review yang ketat sekaligus produktif.

5.2 RQ2 Uji Dua Sampel: Perubahan Laju Bug Pasca Pandas 2.0

Langkah 1: Formulasi Hipotesis

$H_0 : \mu_1 = \mu_2$ (laju bug SAMA pre/post pandas 2.0) $H_1 : \mu_1 \neq \mu_2$ (uji DUA SISI)

Uji dua sisi dipilih karena tidak ada asumsi apriori tentang arah perubahan pasca-rilis major.

Langkah 2: Tingkat Signifikansi

$$\alpha = 0,05.$$

Langkah 3: Statistik Uji

Validitas Z dua sampel: $n_1 = 27$ dan $n_2 = 33$. Independensi terpenuhi karena pemisahan berdasarkan peristiwa eksternal (tanggal rilis perangkat lunak).

$$SE_{diff} = \sqrt{(\lambda_1/n_1 + \lambda_2/n_2)} = 4,1997$$

$$Z = (\lambda_1 - \lambda_2) / SE_{diff} = (60,5556 - 43,3939) / 4,1997 = 17,1617 / 4,1997 = 4,0864$$

Langkah 4: Nilai Kritis

Zkritis = $\pm 1,9600$; daerah penolakan: $|Z| > 1,96$.

Langkah 5: Komputasi Lengkap

Komponen	Nilai
$\bar{x}_1$ (pre-v2.0, $n_1 = 27$)	60,5556 bug/bulan
$\bar{x}_2$ (post-v2.0, $n_2 = 33$)	43,3939 bug/bulan
Selisih ($\bar{x}_1 - \bar{x}_2$)	17,1617 bug/bulan (-28,3%)
SEdiff	4,1997
Zhitung	4,0864
zkritis ($\alpha = 0,05$, dua sisi)	$\pm 1,9600$

p-value	0,000044 ($\approx 4,4 \times 10^{-5}$)
---------	---

Langkah 6: Keputusan dan Kesimpulan

$|Z_{hitung}| = 4,0864 \gg Z_{kritis} = 1,96$ dan $p\text{-value} \approx 4,4 \times 10^{-5} \ll \alpha = 0,05$

$\Rightarrow$ TOLAK H_0 . Ada bukti statistik yang sangat kuat ($p < 0,0001$) menunjukkan bahwa rata-rata jumlah laporan bug per bulan berbeda secara signifikan antara periode sebelum versi 2.0 ($\bar{x}_1 = 60,56$ bug/bulan) dan periode setelah versi 2.0 ($\bar{x}_2 = 43,39$ bug/bulan). Penurunan sebesar 17,16 bug per bulan ($-28,3\%$) konsisten dengan perubahan arsitektur pada pandas 2.0, yang mencakup fitur Copy-on-Write dan peningkatan sistem tipe data. Namun, korelasi tidak berarti ada hubungan sebab-akibat, penurunan tersebut mungkin juga dipengaruhi oleh tingkat kematangan ekosistem atau perubahan dalam cara pelaporan.

6. Computational Analysis

Bagian ini menggunakan tiga teknik komputasional untuk menganalisis dataset *issues* pada proyek *pandas-dev/pandas*, yaitu Monte Carlo Simulation, Bloom Filter, dan Markov Chain Monte Carlo (MCMC). Ketiga teknik dipilih karena mampu memberikan analisis yang sulit diperoleh hanya dari statistik deskriptif biasa.

6.1 Monte Carlo Simulation

Metode dan Justifikasi

Monte Carlo Simulation digunakan untuk mengestimasi probabilitas waktu penyelesaian issue lebih dari 30 hari berdasarkan distribusi empiris data *resolution_days*. Teknik ini dipilih karena distribusi data bersifat *right-skewed* dan memiliki nilai ekstrem, sehingga pendekatan berbasis sampling lebih sesuai dibandingkan metode parametrik yang memerlukan asumsi distribusi tertentu. Simulasi dilakukan dengan mengambil 10.000 sampel acak menggunakan *sampling with replacement* dari kolom *resolution_days*.

Tabel Hasil Simulasi Monte Carlo

Parameter	Nilai	Keterangan
n sampel	10.000	Bootstrap dengan replacement
$P(T > 30 \text{ hari})$	0.4109 (41,09%)	Estimasi probabilitas issue membutuhkan waktu lebih dari 30 hari
Mean Sampel	164,33 hari	Mendekati mean populasi (162,43 hari)
Median sampel	13,88 hari	Menunjukkan distribusi right-skewed
Max sampel	1.942,94 hari	Issue dengan waktu penyelesaian terlama

Interpretasi Hasil dan Hubungan dengan RQ3

Hasil simulasi menunjukkan bahwa sekitar 41,09% issue membutuhkan waktu penyelesaian lebih dari 30 hari. Perbedaan antara mean (164,33 hari) dan median (13,88 hari) menunjukkan distribusi yang menceng ke kanan (*right-skewed*). Hal ini menandakan sebagian besar issue selesai relatif cepat, namun terdapat beberapa issue dengan waktu penyelesaian sangat lama yang meningkatkan nilai rata-rata. Temuan ini mendukung RQ3 dalam menggambarkan pola waktu penyelesaian issue pada repositori *pandas-dev/pandas*.

6.2 Bloom Filter

Metode dan Justifikasi

Bloom Filter digunakan untuk mendeteksi kemungkinan duplikasi issue berdasarkan kolom *title*. Teknik ini dipilih karena memiliki efisiensi memori yang tinggi dan mampu melakukan pengecekan keanggotaan data dengan kompleksitas waktu yang rendah. Implementasi dilakukan menggunakan bit array berukuran 10.000 dan tiga fungsi hash independen.

Tabel Hasil Bloom Filter

Parameter	Nilai	Keterangan
Jumlah data (title)	6.751	Judul issue yang dianalisis
Ukuran bit array	10.000	Konfigurasi Bloom Filter
Jumlah fungsi hash	3	Hash independen
Bit terisi	8.661	Setelah seluruh data dimasukkan
Fill Rate	86,61%	Persentase bit bernilai 1
False Positive Rate (FPR)	65,41%	Estimasi peluang item unik terdeteksi sebagai duplikat
False Negative	0	Karakteristik Bloom Filter

Interpretasi Hasil Hubungan dengan RQ3

Bloom Filter berhasil memproses 6.751 judul issue dengan fill rate sebesar 86,62%. Tingkat pengisian yang tinggi menunjukkan kapasitas bit array mulai jenuh. Nilai False Positive Rate (FPR) sebesar 65,41% mengindikasikan kemungkinan kesalahan identifikasi duplikat yang cukup tinggi, meskipun tidak ditemukan false negative. Temuan ini menunjukkan bahwa konfigurasi Bloom Filter masih perlu dioptimalkan agar hasil deteksi lebih akurat.

6.3 Markov Chain Monte Carlo (MCMC)

Metode dan Justifikasi

MCMC digunakan untuk mengeksplorasi distribusi waktu penyelesaian issue melalui proses sampling berantai menggunakan algoritma Metropolis-Hastings. Teknik ini dipilih karena distribusi *resolution_days* memiliki karakteristik *right-skewed* dan mengandung nilai ekstrem yang cukup besar. Implementasi dilakukan menggunakan 10.000 iterasi dengan data *resolution_days* yang lebih besar dari nol.

Tabel Hasil MCMC

Statistik	Data Asli	MCMC Chain
Mean	162,43 hari	24,72 hari
Median	12,54 hari	4,01 hari

Maksimum	1.942,94 hari	743,99 hari
Jumlah Sampel	6.751	10.000

Interpretasi Hasil Hubungan dengan RQ3

Hasil simulasi MCMC menghasilkan mean 24,72 hari, median 4,01 hari, dan maksimum 743,99 hari. Nilai mean dan median yang rendah menunjukkan bahwa sebagian besar state berada pada waktu penyelesaian issue yang relatif singkat. Namun, nilai maksimum yang masih besar menunjukkan adanya beberapa issue dengan durasi penyelesaian jauh lebih lama. Temuan ini menunjukkan bahwa distribusi waktu penyelesaian issue tetap bersifat *right-skewed* dan memiliki *long-tail cases*, sehingga MCMC dapat menggambarkan variasi durasi penyelesaian issue pada repositori yang dianalisis.

7. Recommendations

Seluruh rekomendasi bersifat spesifik, dapat diimplementasikan, dan langsung didasarkan pada temuan statistik audit ini.

1. Implementasi target SLA dan bot triage otomatis untuk mengatasi penumpukan isu yang berumur panjang.

Langkah strategis ini diambil berdasarkan temuan empiris bahwa 40,79% isu atau sebanyak 2.754 dari 6.751 laporan telah melampaui batas waktu 30 hari, dengan distribusi penyelesaian yang sangat condong ke kanan yang mencatat rata-rata 162,43 hari dan nilai maksimum mencapai 1.942,94 hari. Tanpa adanya sistem eskalasi yang jelas, penumpukan isu pasif atau **backlog zombie** akan terus bertambah. Sebagai langkah mitigasi, bot otomatis berbasis GitHub Actions akan dikonfigurasi untuk memberikan label penapisan khusus pada isu yang tidak mendapatkan respons dalam periode tertentu, yang dikombinasikan dengan penetapan target SLA terukur berdasarkan median empiris 12,54 hari sebagai tolok ukur utama. Sistem ini juga akan didukung oleh agenda pembersihan isu tidak aktif setiap kuartal serta integrasi teknologi Bloom Filter pada pipa penerimaan untuk mendeteksi duplikasi secara otomatis, sehingga mampu memangkas beban kerja manual secara signifikan.

2. mengoptimalkan pipa peninjauan kode serta mengawasi stabilitas angka keberhasilan penggabungan berkas kontribusi.

Walaupun nilai estimasi proporsi saat ini berada pada angka sehat sebesar 0,7085, sebaran waktu penyelesaian kontribusi tersebut masih mengalami ketimpangan akibat adanya kasus pencilan ekstrem yang melebihi 100 hari. Selain itu, keberadaan 941 berkas kontribusi yang ditolak memerlukan investigasi mendalam untuk mengklasifikasikan akar masalahnya ke dalam pedoman kontribusi. Secara teknis, optimalisasi dilakukan melalui rotasi peninjau otomatis berbasis area keahlian untuk mencegah hambatan pada peninjau tunggal, yang dipantau langsung lewat dasbor metrik mingguan. Menggunakan batas bawah interval kepercayaan di angka 0,6928 sebagai ambang batas peringatan, sistem pemantauan runtun waktu akan otomatis memicu jadwal evaluasi khusus jika performa penggabungan berada di bawah batas kritis tersebut selama tiga bulan berturut-turut.

3. menekankan pentingnya mempertahankan tren penurunan laporan bug pasca perilisan arsitektur pembaruan besar dengan mengandalkan audit statistik berkala.

Pengujian hipotesis analitik membuktikan adanya penurunan signifikan laju kerusakan sebesar 28,4% setelah pembaruan versi dilakukan, sehingga tren positif ini harus terus dikawal agar tidak berbalik arah saat peluncuran versi besar di masa mendatang. Untuk memastikannya, pipa audit statistik terotomatisasi yang memproses data dari antarmuka pemrograman aplikasi menuju estimasi

kemungkinan maksimum Poisson hingga uji hipotesis akan dijalankan secara rutin setiap tiga bulan sekali. Sistem pengkondisian alarm akan langsung aktif jika nilai laju gangguan baru melampaui batas atas interval kepercayaan pasca pembaruan sebesar 52,79 bug per bulan. Seluruh metrik utama ini nantinya akan dipublikasikan secara terbuka sebagai indikator kinerja utama pada halaman metrik kesehatan repositori demi meningkatkan transparansi dan kepercayaan para kontributor.

Referensi

- Tsun, A. (2020). Probability & Statistics with Applications to Computing, Ch. 7–9.
- pandas Dev Team. (2023). pandas 2.0.0 Release Notes.
<https://pandas.pydata.org/docs/whatsnew/v2.0.0.html>
- GitHub. (2024). GitHub REST API v3 Documentation. <https://docs.github.com/en/rest>
- Bloom, B. H. (1970). Space/time trade-offs in hash coding with allowable errors. *Comm. ACM*, 13(7), 422–426.
- Gelman, A. et al. (2013). *Bayesian Data Analysis* (3rd ed.). Chapman & Hall/CRC.

Kode analisis: <https://github.com/DRNCW/stat-audit-pandas-Tim7--sti-2025>